

Algoritmi per l'intelligenza artificiale

Simone Colli

`simone.colli@studenti.unipr.it`

Appunti del corso tenuto dal **Prof. Vincenzo Bonnici**

Università degli Studi di Parma

Anno Accademico 2025/2026

Indice

1	Introduzione all'apprendimento automatico	2
1.1	Apprendimento automatico supervisionato	3
1.2	Apprendimento automatico semi-supervisionato	6
1.3	Apprendimento automatico non supervisionato	8
1.4	Apprendimento per rinforzo	11
2	Background	12

Capitolo 1

Introduzione all'apprendimento automatico

Nel campo dell'apprendimento automatico classico, le attività sono tradizionalmente suddivise in quattro rami principali:

- Apprendimento supervisionato (supervised).
- Apprendimento semi-supervisionato (semi-supervised).
- Apprendimento non supervisionato (unsupervised).
- Apprendimento per rinforzo (reinforcement learning).

La distinzione primaria tra queste metodologie di ML risiede nel livello di disponibilità dei “dati di verità di base” (ground truth).

La **ground truth** è definita come la conoscenza preliminare dell'output che il modello dovrebbe produrre per un dato input, basata sull'osservazione diretta in contrapposizione all'inferenza.

1.1 Apprendimento automatico supervisionato

L'apprendimento automatico supervisionato ha come obiettivo l'apprendimento di una funzione che, dato un **campione di dati** e i relativi output desiderati, riesca ad approssimare la funzione sottostante che mappa gli input agli output.

Questa metodologia è comunemente applicata in due principali contesti:

- **Classificazione:** quando si desidera mappare l'input a etichette di output discrete.
- **Regressione:** quando l'obiettivo è mappare l'input a un output continuo.




Figura 1.1: Esempi di apprendimento supervisionato: classificazione e regressione

In entrambi i casi, lo scopo è identificare relazioni o strutture specifiche nei dati di input che consentano di generare output corretti in modo efficace. È fondamentale notare che la correttezza dell'output è determinata interamente dai dati di addestramento, i quali costituiscono la “verità di base” che il modello apprende.

Nota 1.1.1: Importanza della qualità e della quantità dei dati

L'efficacia del modello può essere significativamente ridotta dalla presenza di etichette “rumorose” o “errate” all'interno dei dati stessi.

Oltre alle problematiche legate alla qualità dei dati, è importante considerare anche la quantità. In scenari in cui i dati di addestramento sono limitati o non uniformemente distribuiti, è cruciale optare per un modello a bassa complessità per evitare situazioni di overfitting.

Nota 1.1.2: Esempi di algoritmi supervisionati

Algoritmi notevoli nell'apprendimento supervisionato includono la regressione logistica, il classificatore bayesiano naif, le macchine a vettori di supporto, le reti neurali artificiali e le foreste casuali.

Nota 1.1.3: Complessità del modello

Il successo di un modello di ML dipende dalla sua capacità di generalizzazione. Questo concetto è strettamente connesso alla complessità del modello, che si riferisce alla complessità della funzione che si sta cercando di apprendere.

Overfitting

L'**overfitting** (sovradattamento) è una problematica molto comune che si verifica quando il modello apprende la funzione adattandosi troppo bene ai soli dati di addestramento, senza cogliere la tendenza o la struttura effettiva che guida l'output, e quindi non riesce a generalizzare a nuovi punti dati.




Figura 1.2: Esempi di overfitting

La gestione della generalizzazione è formalizzata tramite il compromesso **bias-varianza** (bias-variance tradeoff). Così facendo il modello presenterà un equilibrio tra:

- **Bias** (distorsione): l'errore sistematico dovuto a ipotesi errate nel processo di apprendimento.
- **Varianza**: la quantità in base alla quale l'errore può variare tra diversi set di dati.

La difficoltà si presenta nel creare un modello che cattura accuratamente le regolarità dei dati di addestramento e che sia in grado di generalizzare bene a dati non visti in precedenza.

In generale, un aumento del bias (e una conseguente riduzione della varianza) porta a modelli con livelli di prestazione più stabili e garantiti, un fattore che può essere cruciale in certe applicazioni.




Figura 1.3: Compromesso bias-varianza

Per ottenere una buona generalizzazione, la varianza del modello deve essere attentamente bilanciata in base alla dimensione e alla complessità dei dati di addestramento.

Nota 1.1.4: Gestione dei dataset

Set di dati piccoli e semplici dovrebbero essere gestiti con modelli a bassa varianza, mentre set di dati grandi e complessi richiedono modelli con una varianza più elevata per poter catturare appieno la struttura sottostante dei dati.

1.2 Apprendimento automatico semi-supervisionato

L'apprendimento automatico semi-supervisionato (semi-supervised) mira a **etichettare un insieme di punti dati senza etichetta** sfruttando la conoscenza appresa da un piccolo numero di dati già etichettati.

Nota 1.2.1: Alcune metodologie comuni

Metodi comuni includono le **macchine vettoriali di supporto trasversali** e i **metodi basati su grafi**, come la propagazione delle etichette.




Figura 1.4: Esempio di apprendimento semi-supervisionato con propagazione delle etichette

Nota 1.2.2: Vantaggi dell'apprendimento semi-supervisionato

L'apprendimento semi-supervisionato può migliorare significativamente le prestazioni del modello rispetto all'apprendimento supervisionato quando si dispone di una quantità limitata di dati etichettati.

Tale limitazione può presentarsi in diversi scenari:

- Dati etichettati costosi da ottenere, ad esempio quando richiedono l'intervento umano.
- Dati etichettati difficili da ottenere, ad esempio quando richiedono competenze specialistiche.
- Dati etichettati soggetti a vincoli di privacy o etici.

Esempio 1.2.1: Rilevamento di messaggi inappropriati

Nel rilevamento di messaggi inappropriati in un social network, è impraticabile etichettare manualmente ogni messaggio. È possibile, invece, etichettare manualmente un piccolo sottoinsieme e usare tecniche semi-supervisionate per comprendere e classificare il resto dei contenuti.

Presupposti dell'apprendimento semi-supervisionato

Per poter giustificare l'utilizzo di pochi dati etichettati per trarre conclusioni su un grande insieme di dati non etichettati, i metodi semi-supervisionati si basano su alcuni presupposti fondamentali, quali:

- **Continuità:** Si assume che punti dati “vicini” tra loro abbiano maggiori probabilità di condividere la stessa etichetta.
- **Ipotesi del cluster:** Si presume che i dati formino naturalmente dei cluster discreti. Di conseguenza, punti nello stesso cluster hanno maggiori probabilità di condividere un'etichetta.
- **Presupposto molteplice (manifold):** Si ipotizza che i dati si trovino approssimativamente in uno spazio di dimensioni inferiori (un *manifold*) rispetto allo spazio di input originale.

L'ultimo presupposto è particolarmente rilevante in scenari quando un sistema con pochi parametri, non osservabile direttamente, produce output osservabili ad alta dimensione.

1.3 Apprendimento automatico non supervisionato

L'apprendimento automatico non supervisionato (unsupervised) opera **senza output etichettati**. L'obiettivo principale di questa tecnica è quello di **dedurre la struttura naturale** presente all'interno di un insieme di dati, cercando di trovare **pattern intrinseci** nei dati. Le attività più comuni in questo ambito includono:

- **Clustering** (raggruppamento).
- **Apprendimento della rappresentazione** (representation learning).
- **Stima della densità** (density estimation).

Nota 1.3.1: Valutazione delle prestazioni

Dato che non vengono fornite etichette, nella maggior parte dei metodi di apprendimento non supervisionato non esiste un modo specifico per confrontare le prestazioni del modello.

Clustering

Il clustering è una **tecnica esplorativa** che permette di aggregare dati in gruppi (detti *cluster*) senza avere una precedente conoscenza della loro appartenenza a tali gruppi. Si applica a dataset dove i dati al loro interno presentano elementi simili tra loro.




Figura 1.5: Esempio di clustering

All'interno di ogni singolo cluster si troveranno quindi dati che hanno molte **caratteristiche simili** tra loro. È un'ottima tecnica per trovare relazioni tra i dati.

Riduzione della dimensionalità

La riduzione della dimensionalità senza supervisione è un approccio molto usato nella **pre-elaborazione delle features**. L'obiettivo principale di questa tecnica è di **eliminare il "rumore"** dai dati. Un

altro utilizzo si trova nella **rappresentazione dei dati**: dati in uno spazio delle caratteristiche ad elevata dimensionalità possono essere proiettati su uno spazio 1D, 2D o 3D per l'analisi visiva.




Figura 1.6: Esempio di PCA e scree plot

Nota 1.3.2: Compromesso tra riduzione della dimensionalità e prestazioni

Questa operazione può talvolta causare una minore prestazione predittiva. Ma può anche rendere lo spazio dimensionale più compatto, aiutando a **mantenere le informazioni più rilevanti**.

Analisi esplorativa

L'apprendimento non supervisionato è estremamente utile nell'**analisi esplorativa dei dati** (exploratory data analysis), poiché è in grado di **identificare automaticamente la struttura** nei dati.




Figura 1.7: Esempio di analisi esplorativa con clustering gerarchico

Esempio 1.3.1: Segmentazione dei consumatori

Se un analista volesse segmentare i consumatori, i metodi di clustering sarebbero un ottimo punto di partenza per l'analisi.

Nota 1.3.3: Utilizzo in assenza di etichette

In situazioni dove è impraticabile o impossibile per un essere umano proporre tendenze nei dati, l'apprendimento non supervisionato può fornire **informazioni iniziali** che possono poi essere usate per testare o verificare singole ipotesi.

1.4 Apprendimento per rinforzo

L'apprendimento con rinforzo (reinforcement learning) ha l'obiettivo di realizzare **agenti autonomi**. Questi agenti devono essere in grado di scegliere azioni da compiere per conseguire determinati obiettivi. Questo avviene tramite l'interazione con l'ambiente in cui sono immersi, con lo scopo di massimizzare una nozione di **premio cumulativo**.

Capitolo 2

Background